



TOKOPEDIA



Astro Lihardo Aloysius
Emily Vitasya Haloho
Fransiskus B Simanjorang





PURWADHIKA



Data and Business Understanding

- Latar Belakang:
 - Tokopedia merupakan platform e-commerce terkemuka di Indonesia dengan jutaan pengguna aktif dan ratusan ribu transaksi harian.
 - Perusahaan bergeser dari strategi growth-driven (bakar uang/subsidi) ke profitability-driven akibat tingginya Customer Acquisition Cost (CAC) yang tidak sebanding dengan Customer Lifetime Value (CLV).





Masalah


01.

Lonjakan Customer Acquisition Cost (CAC) tidak sebanding dengan Customer Lifetime Value (CLV), memicu churn tinggi setelah periode promo selesai

02.

Terjadi glitch sistem saat traffic puncak (flash sale) yang mengakibatkan log data kotor, format tidak standar, dan timestamp tidak logis.





Tujuan

01. Memproses dan membersihkan data historis operasional.

02. Menganalisis pola transaksi, perilaku pengguna, dan performa logistik guna mendukung pengambilan keputusan bisnis yang efisien.





Ringkasan Singkat

01.


tokopedia_users.csv
(50.000 baris):
Menyimpan data
demografi pengguna,
lokasi, usia, dan
tanggal bergabung.


02.

tokopedia_transactions.csv (300.000 baris):
Menyimpan informasi
order, metode
pembayaran, nominal
promo, dan total
belanja.

03.


tokopedia_deliveries.csv (300.000 baris):
Menyimpan data
logistik, kurir, tanggal
dispatch, dan tanggal
delivery.





DATA QUALITY REPORT





DATA QUALITY REPORT

Kondisi Umum:

- 01.** Ekstraksi dari sistem menunjukkan adanya inkonsistensi data, nilai kosong serta anomali akibat lonjakan trafik (seperti saat flash sale).

Metodologi Penilaian:

- 02.** Menggunakan kerangka identifikasi Missing Values (MCAR, MAR, dan MNAR) untuk memastikan penanganan data kosong tidak menimbulkan bias statistik
-






Temuan



Temuan 1:

Adanya missing values pada kolom gender di tabel users (~9,79%) dan courier_name di tabel deliveries (~5,03%).



Temuan Dua

Anomali finansial pada total_amount, meliputi nilai negatif (~3.032 baris indikasi refund), nilai nol, hingga nilai ekstrem mencapai Rp 1 miliar.



Temuan Tiga

Inkonsistensi format teks pada kolom payment_method (contoh: variasi penulisan 'GoPay', 'gopay', 'GO-PAY') serta perbedaan penamaan Virtual Account.



Temuan Empat

Anomali kronologi tanggal, di mana terdapat order_date sebelum join_date (~15.000 baris) dan delivery_date mendahului dispatch_date (~9.000 baris).




2.2 Kerangka Identifikasi Missing Values

- MCAR (Missing Completely At Random): Kekosongan data murni acak tanpa pola. Contoh: Kolom gender. Penanganan: Aman di-impute atau di-drop.
- MAR (Missing At Random): Kekosongan berkaitan dengan kolom lain. Contoh: Kolom courier_name terkait metode pembayaran. Penanganan: Imputation berbasis kolom lain.
- MNAR (Missing Not At Random): Kekosongan terjadi secara sistematis dan membawa informasi bisnis (contoh: pesanan batal sebelum pickup). Penanganan: Dipertahankan sebagai NaN bermakna atau diberi flag.


2.2

Kerangka 01. Identifikasi Missing Values



Missing Values pada Kolom gender (Tabel Users)

- Terdapat 4.894 baris yang kosong atau sekitar 9,79% dari total 50.000 data pengguna.
- Penanganan: Diasumsikan dihapus karna tidak berpengaruh dengan kolom lain



02.

Missing Values pada Kolom courier_name (Tabel Deliveries)


- Terdapat 15.085 baris yang kosong atau sekitar 5,03% dari total 300.000 data pengiriman.
- Penanganan: Tidak dihapus atau di-impute sembarangan, karena beberapa kurir tertentu diasumsikan belum terintegrasi ke sistem

03

Missing Values pada Kolom courier_name (Tabel Deliveries)

- courier_name kosong karena transaksi belum diproses/dibatalkan sebelum pickup.
- Penanganan : dipertahankan sebagai NaN






2.3

Penanganan Kolom `payment_` `method`

- Standarisasi menyederhanakan data, tetapi penggabungan kategori (seperti 'GOPAY' menjadi 'Gopay')
- Implementasi: Membuat fungsi mapping atau standarisasi string ke format yang konsisten dan menyimpannya ke kolom baru (`payment_method_clean`).
- Untuk metode pembayaran dengan Virtual Account Bank tidak disatukan karna perbedaan bank menghasilkan perbedaan keputusan bisnis yang berbeda






2.4

Penanganan

**total_
amount**

- Memberikan label/flag khusus. Dengan begitu, data ini bisa dieksklusi saat menghitung rata-rata, tetapi tetap dimasukkan saat menghitung total GMV keseluruhan.
- Nilai negatif diasumsikan berasal dari refund yang terdapat pada transaksi terpisah
- Nilai 1 miliar diasumsikan pembelian dalam jumlah besar atau bulk oleh reseller





2.5


Penanganan Anomali Tanggal

Jumlah order sebelum join_date: 15000

Jumlah delivery sebelum dispatch: 9000

- (dispatch_date menjadi sebelum delivery_date) durasi pengirimannya masuk akal secara logistik (misalnya 1-3 hari), maka lakukan swap tanggal secara otomatis.
- Swap order menjadi join date
- Swap delivery date menjadi setelah delivery date
-






2.5

Penanganan Anomali Tanggal


- Nilai negatif bisa jadi merupakan pencatatan refund/return, dan nilai Rp1 miliar bisa jadi sah (legitimate) sebagai pembelian bulk oleh reseller.
- Keputusan penanganan harus konsisten: penghapusan outlier untuk analisis harga rata-rata belum tentu boleh diterapkan langsung jika sedang menghitung total GMV keseluruhan.
- Implementasi: Melakukan analisis distribusi nilai anomali, menetapkan batasan (threshold) yang terjustifikasi, serta memutuskan apakah anomali tersebut akan di-drop, di-cap, atau diberi flag khusus sebagai kategori tersendiri.



2.6


Penanganan Missing Values pada 'courier_ name'

- Jika murni karena Cancelled: Pertahankan sebagai NaN bermakna atau buat kategori baru yang eksplisit seperti Cancelled_Before_Pickup.
- Jika karena kendala sistem/integrasi: Isi dengan kategori 'Unknown' agar baris data tetap bisa digunakan dalam analisis tren volume pengiriman secara keseluruhan tanpa merusak struktur dataset.



2.7

Penanganan Duplikat & Integritas Data



- Jika murni karena Cancelled: Pertahankan sebagai NaN bermakna atau buat kategori baru yang eksplisit seperti Cancelled_Before_Pickup.
- Jika karena kendala sistem/integrasi: Isi dengan kategori 'Unknown' agar baris data tetap bisa digunakan dalam analisis tren volume pengiriman secara keseluruhan tanpa merusak struktur dataset.



Terima Kasih

